
Python資料分析與機器學習應用



旅遊小幫手

生傳三 黃韻文 | 財金三 黃敏瑄 | 物理四 簡詩汶社工三 王柏詒 | 機械四 賴欣妤



大綱

- 1 最終成果預期之重要性與貢獻性
- 2 專案內容介紹(含差異)
- 3 資料清理與模型
- 4 專案 demo



最終成果預期之

重要性與貢獻性

專案重要性

專案價值

觀光統計年報資訊過量

- 報告達 480 頁,缺乏視覺化圖表
- 趨勢分析僅依季度與區域,無針對個別景點
- 建議僅針對大方向,無個別地區細緻化的發展建議

少以數據為主的建議

- 少有以實證資料為主的研究建議
- 網路社群的旅遊評價多描述「主觀感受」

- 改善數據量過大、可讀性低、資料分散等問題
- 以視覺化數據協助旅客作出判斷

專案價值

疫情趨緩後,國旅商機恢復,旅遊變得越加重要,而我們的專案...

旅客

- 評估各行政區域的房價均值
- 旅遊選址時搭配房價作參考

旅宿業者

- 依據每月人流預測調整預算投入
- 依據旅遊型態分析擬定營運策略



事案內容介紹


期中期末比較

專案介紹

專案主題	期中規劃	期末調整	完成度
預測	使用政府開放資料爬取天氣、平假日、房價預測未來每日人流量	景點每月人流量預測旅館每日房價預測	90%
分析	觀光局每月景點人流量爬取天氣、平假日景點分群、行銷建議	無	100%
呈現	自架網站	無	100%

專案介紹

功能:房價查詢、景點分群說明





事案 Demo




資料前處理與建模


房價預測

景點人流預測

KMEANS-模型



cluster the data into n clusters using K-Means clf_KMeans = KMeans(n_clusters= 2, random_state=0, n_init="auto") y_pred = clf_KMeans.fit(X_true) ## 分群 print(y_pred)



cluster the data into n clusters using K-Means clf_KMeans = KMeans(n_clusters= 4, random_state=0, n_init="auto") y_pred = clf_KMeans.fit(X_true) ## 分群 print(y_pred)


351 個景點資料

房價預測

景點人流預測

KMEANS-模型








Group 2 -- Visitors of Top 10 Spots Spot_name --- 大鵬灣遊憩區 大鵬灣

Group 1 -- Visitors of Top 10 Spots



景點人流預測

房價預測

觀光局資料集

Taixvan 交通部觀光局觀光統計資料庫
Tourism Statistics Database of the Taiwan Tourism Bureau

回首頁Home 網站導覽Sitemap

	料庫簡介 來臺資料 troduction Inbound visitors	出國資料 Outbound travelers	觀光遊憩據點 Scenic Spots	郵輪旅客 Visitor Arrivals by cruise	統計報表 Statistics								
首頁 Home / 觀光並	遊憩據點 Scenic Spots												
觀光遊憩掘	_{象點} Scenic Spo	ots											
單一類別查詢 Single Category Search			類別查詢 egory Search	Recor		更名紀錄 names of recreational areas							
統計方式 (Year or Month)	○年表(Year)	月表(Month)											
時間區間 (Time)	112(2023) 🗸 3		2023) 🗸 3	~									
	※觀光局每年選定之觀光遊憩拡 ※				予加缩。								
				遊憩據點 Scenic spots									
請選擇區域(Select) 請選擇縣市(Select)													
	চ(Select) ✔												
全部 (All)			施安连咚游刮匣 Λ	/anliao Eujong Pocreatio	n Area)								
全部 (All) 鼻頭龍洞遊憩區 (Bitou Longdong Recre	eation Area)			'anliao Fujong Recreatio 'ilan Ocean Recreation A	•								
全部 (All)	eation Area)			ilan Ocean Recreation A	•								
全部 (All) 鼻頭龍洞遊憩區 (Bitou Longdong Recre 大里外澳遊憩區 (Dali Waiao Recreation	eation Area)		宜蘭濱海遊憩區 (\] 三仙臺 (Sansianta	ilan Ocean Recreation A	•								
全部 (All)	eation Area)		宜蘭濱海遊憩區(N] 三仙臺 (Sansianta] 秀姑巒溪遊客中心	ilan Ocean Recreation A	Area)	adquarters)							
全部 (All)	eation Area)		宜蘭濱海遊憩區(N 三仙臺(Sansianta 秀姑巒溪遊客中心 都歷處本部(East(rilan Ocean Recreation A ni) (Siouguluan River)	Area) rea Administration Hea	adquarters)							

label / one-hot encoding

pandas.melt

Spot_name	Spot_type	County	Year	Jan	Feb	Mar	Apr	May
陽明山遊客中心	國家公園	臺北市	2012	12187.0	18612.0	18580.0	13329.0	14179.0
陽明書屋	國家公園	臺北市	2012	2597.0	3617.0	5221.0	4317.0	3497.0
陽明公園	國家公園	臺北市	2012	161000.0	463000.0	705200.0	85600.0	38600.0
大屯遊憩區	國家公園	臺北市	2012	17047.0	29079.0	38558.0	34332.0	43906.0
龍鳳谷遊憩區	國家公園	臺北市	2012	21201.0	22134.0	62447.0	64691.0	16243.0

label / one-hot encoding

pandas.melt

Spot_code	County_encode	Spot_type_encode	population	Year	month
0	13	3	12187.0	2012	1
1	13	3	2597.0	2012	1
2	13	3	161000.0	2012	1
3	13	3	17047.0	2012	1
4	13	3	21201.0	2012	1

Label / OntHot Encoder

```
from sklearn.preprocessing import LabelEncoder
labelencoder = LabelEncoder()
data_le = labelencoder.fit_transform(df[['County']])
df['County_encode'] = data_le
data_le = labelencoder.fit_transform(df[['Spot_type']])
df['Spot_type_encode'] = data_le
```

把前幾個月的人流量當成 feature

	Year	Spot_code	County_encode	Spot_type_encode	month	population	group	la
	2015	1	13	3	1	2811.0	0	
	2016	1	13	3	1	2846.0	0	
	2017	1	13	3	1	2834.0	0	
	2018	1	13	3	1	1616.0	0	
ı	2019	1	13	3	1	8761.0	0	
•								

р	last_month_ppl	last_2_month_ppl	last_3_month_ppl
0	2446.0	3010.0	2597.0
0	2811.0	2446.0	3010.0
0	2846.0	2811.0	2446.0
0	2834.0	2846.0	2811.0
0	1616.0	2834.0	2846.0

人流量預測 - DNN 模型

```
class My_spot_Model(nn.Module):
   def init (self, input dim):
        super(My_spot_Model, self).__init__()
        self.layers = nn.Sequential(
           nn.Linear(input dim, 128),
           nn.LeakyReLU(),
           nn.Linear(128, 48),
           nn.LeakyReLU(),
           nn.Linear(48, 16),
           nn.LeakyReLU(),
           nn.Linear(16, 24),
           nn.LeakyReLU(),
           nn.Linear(24, 8),
           nn.LeakyReLU(),
           nn.Linear(8, 1),
           nn.ReLU(),
```

可調參數

valid_ratio: 0.2

• n_epochs: 3000

• batch size: 256


• learning_rate: 1e-3

early_stop: 300


不同資料集版

- one-hot encode / label encode
- MinMaxScaler / StandardScaler

training loss



valid loss




MSE: 61861.75

```
from sklearn.metrics import mean_squared_error
mean_squared_error(test_data[:, -1], preds, squared=False)
```

景點人流預測

房價預測

Airbnb網站爬蟲



地區、價錢



Boutique hotel in Zhongsh... ★ 4.79 (71)

設計風旅店 在家行旅 公園景觀豪華雙人...

1bed

Jun 13 - 18


\$2,496 TWD night



ent in Da'an Distri... ★ 4.78 (277) count 獨享浴缸 East zone@100+...

22

FWD \$1,892 TWD night



Apartment in Wanhua District ★ New Charming Apt 20secsTo Ximen MRT 1 bed
Jun 12 – 17
\$1,952 TWD night

景點人流預測

房價預測

Airbnb網站爬蟲

```
def scrap this page(dataframe, url, checkin, checkout, adults, children, infants, pets):
    # Create selector
   html = requests.get(url).content
    sel = Selector(text=html)
                                                                                                     爬此頁
    hotels = sel.css('div.c4mnd7m')
   # Select the first announcement from the previous list of 20
    for i in range(len(hotels)):
       hotel = hotels[i]
       # Get main information
                       = hotel.css('div[data-testid="listing-card-title"] ::text').extract_first()
       title
                       = hotel.css('span._tyxjp1 ::text').extract_first()
       price
           ori_price = hotel.css('span._1ks8cgb ::text').extract_first()
           dis_price = hotel.css('span._1y74zjx ::text').extract_first()
       else:
           ori_price = price
           dis price = price
                                                                                                             加入 dataframe
                       = hotel.css('span.r1dxllyb ::text').extract_first()
       rating
                        = hotel.css('a.bn2bl2p ::attr(href)').extract_first()
       url
       dataframe.loc[len(dataframe)] = [title, ori_price, dis_price, rating, checkin, checkout, adults, children, infants, pets, timestamp, main_url+url
                                                                     進入下一頁
def to_next_page(sel, page_i):
   next_page = sel.css('a.c1ackr0h ::attr(href)').extract()[page_i]
   return f'{main url}{next page}'
```

```
def scrap_weather():
    import requests
    import pandas as pd
    from datetime import datetime
    df pre = pd.DataFrame(columns=('date', 'region',
                               'rain_0','rain_1','rain_2','rain_3','rain_4','rain_5','rain_6',
                               'temp_0','temp_1','temp_2','temp_3','temp_4','temp_5','temp_6',
                               'humi_0','humi_1','humi_2','humi_3','humi_4','humi_5','humi_6')
    url = 'https://opendata.cwb.gov.tw/api/v1/rest/datastore/F-D0047-063?Authorization=CWB-8CB6
    data = requests.get(url)
    data_json = data.json()
    location = data_json['records']['locations'][0]['location']
    for i in range(len(location)):
        rain = location[i]['weatherElement'][0]
        temperature = location[i]['weatherElement'][1]
        humidity = location[i]['weatherElement'][2]
```

爬取當天-六天後的雨量、氣溫、濕度

資料從氣象局 開放的 api 擷取

Replace string with regex

```
df = pd.read_csv('airbnb_taipei_spec_date_clean_copy.csv', encoding='unicode_escape')
df = df.replace({"Ã": "", "f": "", "Â":"", ",":"", "TWD": "", ",":"", " ": "", r'\xa0':"", "\$": ""}, regex=
```

Normalization

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
train.iloc[:, :-1] = scaler.fit_transform(train.iloc[:, :-1])
test.iloc[:, :-1] = scaler.transform(test.iloc[:, :-1])
```

ori_price

\$3,000Â TWD \$3,000Â TWD

\$2,800Â TWD \$2,800Â TWD

title

Hotel in

District

Zhongzheng

Apartment

Zhongshan

景點人流預測

2023-05-

2023-05-

29

2023-

05-28

2023-

05-28

房價預測

2023-05-28 16:35:00

2023-05-28 16:35:00

資料整併

https://www.airbnb.com/rooms/638252082882106842?adults=

https://www.airbnb.com/rooms/577259487465118795?adults=

28&check out=2023-05-29&previous page section name=1000&fee

28&check_out=2023-05-29&previous_page_section_name=1000&fee

原 始 數

併

數

據

加尔	

Air	bn	b爬	蟲資	資料

dis_price rating

NaN

(merge) 捷運站數資料

checkin checkout adults children infants pets timestamp

(merge) 天氣爬蟲資料

	adults	children	infants	pets	checkin_weekday	discount	title_code	mrt_count	rain_0	rain_1	temp_0	temp_1	humi_0	humi_1	dis_price
0	0.933333	0.733333	0.6	0.0	0.666667	0.000000	0.363636	1.000000	0.285714	0.000000	0.666667	0.428571	0.310345	0.190476	25106.000000
1	0.066667	0.066667	0.2	0.6	0.500000	0.000000	0.363636	1.000000	0.285714	0.000000	0.666667	0.428571	0.310345	0.190476	2538.000000
2	0.200000	0.066667	8.0	0.2	0.666667	0.000000	0.363636	1.000000	0.142857	0.000000	0.333333	0.571429	0.103448	0.095238	4770.000000
3	0.000000	0.000000	0.2	0.0	0.500000	0.004729	1.000000	0.888889	0.857143	1.000000	0.166667	0.285714	0.758621	0.714286	950.181818
4	0.200000	0.000000	0.2	0.6	0.166667	0.000000	1.000000	0.888889	0.571429	0.666667	0.166667	0.285714	0.793103	0.809524	1381.000000

Airbnb - DNN 模型

可調參數

valid_ratio: 0.2

• n_epochs: 3000

• batch size: 256


• learning_rate: 1e-3

early_stop: 300


不同資料集版

- one-hot encode / label encode
- MinMaxScaler / StandardScaler

training loss



valid loss



MSE: 549.04

```
from sklearn.metrics import mean_squared_error
mean_squared_error(test_data[:, -1], preds, squared=False)
```

Python資料分析與機器學習應用



旅遊小幫手

感謝大家

